ZAVRŠNI ISPIT IZ DIGITALNE OBRADBE I ANALIZE SLIKE (2012/2013)

1.

a) Izračunajte histogram prvog reda slike S (skicirajte ga).

b) Objasnite Tomita metodu segmentacije. Segmentirajte sliku S Tomita metodom.

c) Izračunajte histogram drugog reda slike S, ako je međusobna pozicija dviju točaka dana izrazom $S = S(m,n)$ i $S' = S(m+1, n+1)$ (prilikom izračuna slike S' pretpostavite da su izvan matrice vrijednosti 0). Izračunajte dvije značajke histograma drugog reda slike S.

d) Izračunajte horizontalnu i vertikalnu projekciju slike S. Navedite primjere za što se one mogu koristiti.

$$S = \begin{bmatrix} 1 & 3 & 5 & 4 & 8 \\ 8 & 5 & 8 & 5 & 4 \\ 8 & 3 & 1 & 0 & 5 \\ 1 & 4 & 1 & 0 & 4 \\ 0 & 3 & 1 & 0 & 4 \end{bmatrix}$$

2.

a) Objasnite efekt gradijentnih operatora (njihove prednosti i mane). Navedite primjer gradijentnog operatora i što on detektira.

b) Navedite svojstva filtra za uklanjanje šuma prostornim usrednjavanjem i medijan filtra. Kada se koji od njih primjenjuje? Filtriraj sliku S iz gornjeg zadatka medijan filtrom $3x3$ (Napomena: filtriranje vršimo tako da su ulazna i izlazna slika jednakih dimenzija).

3.

a) Napišite pseudokod Houghove transformacije. Skicirajte Houghovu transformaciju točaka u slici I. Izračunajte Houghovu transformaciju pravaca na kojima leže točke dane slikom I.

$$I = 2\begin{bmatrix} 1 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix}$$

4.

a) Objasnite kako se optički tok koristi u analizi pokreta (izvedite izraze, u kojim slučajevima oni vrijede i koji su problemi navedene metode).

b) Objasnite Horn-Schunck algoritam.

c) Navedite pseudokod segmentacije grupiranjem (*K-means clustering*).

d) Objasnite metodu analize oblika korištenjem energije savijanja.

e) Objasnite metodu transformacije simetrične osi.

(1)

$$S = \begin{bmatrix} 1 & 3 & 5 & 4 & 8 \\ 8 & 5 & 8 & 5 & 4 \\ 8 & 3 & 1 & 0 & 5 \\ 1 & 4 & 1 & 0 & 4 \\ 0 & 3 & 1 & 0 & 4 \end{bmatrix}$$

a)

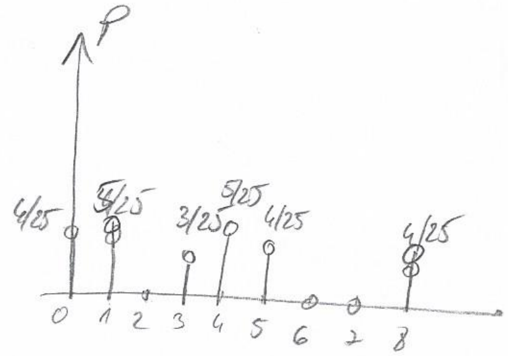

b) Tomita segmentacija je rekurzivna metoda sliku podijelimo na dvije regije prema pragu određenom iz hist. prvog reda. Potom se nad svakom regijom radi hist 1. reda. ako je on bimodalan, regija se dijeli na dva. Segmentacija se provodi dok sve regije ne postanu unimodalne

1) prag = 2

$$S_{maska_1} = \begin{bmatrix} 1 & 2 & 2 & 2 & 2 \\ 2 & 2 & 2 & 2 & 2 \\ 2 & 2 & 1 & 1 & 2 \\ 1 & 2 & 1 & 1 & 2 \\ 1 & 2 & 1 & 1 & 2 \end{bmatrix}$$

1 - prva regija

2 - druga regija

$H_1 \Rightarrow$

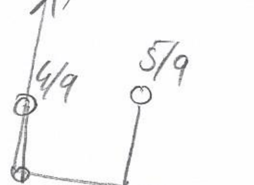

$H_2 \Rightarrow$

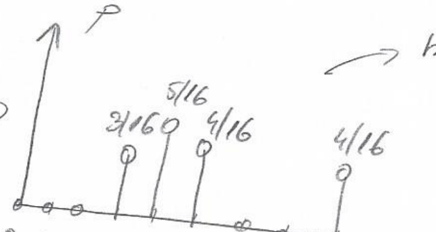

→ bimodalan

2) prag = 6 (za drugu regiju)

$$S_{maska_2} = \begin{bmatrix} 1 & 2 & 2 & 2 & 3 \\ 3 & 2 & 3 & 2 & 2 \\ 3 & 2 & 1 & 1 & 2 \\ 1 & 2 & 1 & 1 & 2 \\ 1 & 2 & 1 & 1 & 2 \end{bmatrix}$$

3 - treća regija

c)

$$S' = S(m+1, n+1)$$

$$S = \begin{bmatrix} 1 & 3 & 5 & 4 & 8 \\ 8 & 5 & 8 & 5 & 4 \\ 8 & 3 & 1 & 0 & 5 \\ 1 & 4 & 1 & 0 & 4 \\ 0 & 3 & 1 & 0 & 4 \end{bmatrix}$$

$$P(x_1, x_2) = \begin{array}{c} \\ 0 \\ 1 \\ 2 \\ 3 \\ 4 \\ 5 \\ 6 \\ 7 \\ 8 \end{array} \begin{array}{c} \begin{array}{ccccccccc} 0 & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 \end{array} \\ \begin{bmatrix} 0 & 0 & 0 & 0 & 2 & 0 & 0 & 0 & 0 \\ 2 & 0 & 0 & 1 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 & 0 & 2 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \end{bmatrix} \end{array} \cdot \frac{1}{16}$$

Energija

$$E = \sum_{x_1=0} \sum_{x_2=0} |P(x_1, x_2)|^2 = 21$$

Entropija

$$H = \sum_{x_1=0} \sum_{x_2=0} P(x_1, x_2) \log_2 P(x_1, x_2) = 4$$

d)

2 a) Gradjentni operator definiran je s dvije maske koje mjere gradijent slike u 2 ortogonalna smjera. Konvolucija maski i slike daje rezultate

$$g_1(m,n) = \sum_i \sum_j h_1(i,j)\, u(m-i, n-j)$$
$$g_2(m,n) = \sum \sum h_2(i,j)\, u(m-i, n-j)$$

Potom se računa smjer i iznos gradijentnog vektora

$$g(m,n) = \sqrt{g_1^2(m,n) + g_2^2(m,n)} \quad , \quad \vartheta_g(m,n) = \operatorname{arctg}\left(\frac{g_2(m,n)}{g_1(m,n)}\right)$$

Mana: osjetljivost na šum koja se rješava povećanjem maske veća maska jače zamućuje sliku te onemogućava točnu lokalizaciju ruba

Prednost: jednostavnost

Sobel: $\begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix} \downarrow \quad , \quad \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix} \rightarrow$

b) Prostorno usrednjavanje $\frac{1}{9}\begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$ (avg filter) svaku točku slike postavlja tako da predstavlja srednju vrijednost s obzirom na okolinu pokrivenu maskom – Gaussov šum

Medijan točku postavlja u vrijednost koja je po svojem iznosu u sredini, s obzirom na okolinu zadanu maskom – impulsni šum

$$S_{AVG} = \begin{bmatrix} 17 & 10 & 30 & 34 & 21 \\ 28 & 42 & 34 & 40 & 26 \\ 29 & 39 & 27 & 28 & 18 \\ 19 & 22 & 13 & 16 & 13 \\ 8 & 10 & 9 & 10 & 8 \end{bmatrix} \cdot \frac{1}{9} \qquad S_{MED} = \begin{bmatrix} 0 & 3 & 4 & 4 & 0 \\ 3 & 5 & 4 & 5 & 4 \\ 3 & 4 & 3 & 4 & 0 \\ 1 & 1 & 1 & 1 & 0 \\ 0 & 1 & 0 & 0 & 0 \end{bmatrix}$$

(3.) Inicijaliziraj Houghovo polje na nulu $A(\rho, \varphi) = 0$

Za svaku točku (x,y) u slici za koju je $S(x,y) = 1$

$\forall \varphi = [0, \varphi_{max}]$

$\rho = x \cdot \sin(\varphi) + y \cdot \cos(\varphi)$

Kvantiziraj dobiveni ρ za odabrani φ

$A(\rho, \varphi) = A(\rho, \varphi) + 1$

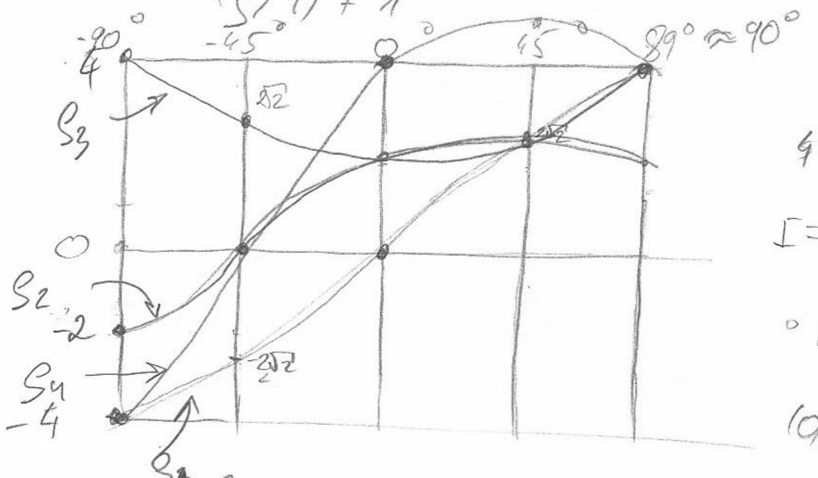

$$
\begin{array}{cc}
4 & \\
I = & \begin{bmatrix} 1 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix} \cdot 2 \\
0 & \qquad\qquad 4
\end{array}
$$

$(0,4), (2,2), (4,0), (4,4)$

$\rho = x \cos\vartheta + y \sin\vartheta$

$\rho_1 = 4 \sin\vartheta$

$\rho_2 = 2\cos\vartheta + 2\sin\vartheta$

$\rho_3 = 4\cos\vartheta$

$\rho_4 = 4\cos\vartheta + 4\sin\vartheta$

(4) a) Pretpostavka je da se svjetlina ne mijenja

Neka je $I(x,y,t)$ svjetlina slike u točki s koordinatama (x,y) u trenutku t. Ako je (x,y) dio objekta koji se pomakne tada vrijedi

$$I(x,y,t) = I(x+dx, y+dy, t+dt)$$

$I_x dx + I_y dy + I_t dt = 0$, $\left[I_x = \frac{dI}{dx}, I_y = \frac{dI}{dy}, I_t = \frac{dI}{dt}\right]$

$I_t dt = -(I_x dx + I_y dy) / \frac{1}{dt}$

$I_t = -(I_x v_x + I_y v_y)$ => v_x i v_y su brzine u x i y smjeru

$v = \begin{bmatrix} v_x \\ v_y \end{bmatrix} \Rightarrow I_t = -\nabla I \cdot v$

PROBLEMI

1) Imamo jednu jednadžbu a dvije nepoznanice brzine

2) vremenski i prostorni gradijent ne možemo točno odrediti već samo procijeniti

b) Horn Schunck algoritam svodi problem računanja optičkog toka na problem minimizacije izraza koji se sastoji od dva člana

$E_1 = I_x v_x + I_y v_y + I_t$ - odstupanje od jdbe za optički tok (u idealnom slučaju $\emptyset$)

$E_2 = \left(\frac{\delta v_x}{\delta x}\right)^2 + \left(\frac{\delta v_x}{\delta y}\right)^2 + \left(\frac{\delta v_y}{\delta v_x}\right)^2 + \left(\frac{\delta v_y}{\delta v_y}\right)^2$ - zahtjeva glatkoću vektorskog polja

c) Inicijaliziraj k na broj koliko grupa želiš

k-puta nasumično odredi centar grupe „u" u nultoj iteraciji

$u(0) = rand$

while $(u(n) \neq u(n+1))$ {

odaberi vektor x_i i dodijeli ga grupi čijem je centru najbliži

$x_i \in R_i \iff d(x_i, u_i(n)) = \min_{j=1,\dots,k} \{d(x_i, u_j(n))\}$

izračunaj nove centre grupa

$u(n+1) = \sum_{x_i = R_x} d(x_i, u_k(n+1)) = \min_y \{d(x_i, y)\}, k = 1, \dots, K$

}

d) Oblik se može opisati svojom energijom savijanja

$$E = \frac{1}{P} \int_0^P |K(p)|^2 dp$$, gdje je $K(p)$ zakrivljenost, a P je opseg oblika. Krug ima najmanju energiju savijanja

e) transformacija simetrične osi temelji se na pronalaženju kostura oblika. Transformacija se opisuje vatrom koja započinje na rubovima oblika te propagira jednolikom brzinom okomito na rub s kojeg je krenula. Točke gdje će se vatrene fronte spojiti nazivaju se <u>točke sudara</u>, a unija svih točki sudara čini <u>kostur</u>