1.1. DEFINIRAJTE 1D KARHUENEN-LOEVE TRANSFORMACIJU

Neka je u realan slučajni vektor duljine N

Autokorelacijska matrica vektora u je $R = E[u u^T]$

Neka je A $N \times N$ matrica čiji su stupci ortonormalizirani vlastiti vektori matrice R

$$R a_k = \lambda_k a_k \qquad 0 \leq k \leq N-1 \qquad \lambda_0 \geq \lambda_1 \geq \ldots \geq \lambda_{N-1}$$

A - unitarna matrica koja reducira R na dijagonalnu formu

$$Q = A^H R A$$

1-D KL

$$V = A^H u \quad / \quad \text{inverzna 1-D KL} \quad u = AV = \sum_{k=0}^{N-1} v(k) a_k$$

1.2. ZADANA JE AUTOKORELACIJSKA MATRICA

$$R = \begin{bmatrix} 4 & 0 & -2 \\ 0 & 2 & 0 \\ -2 & 0 & -4 \end{bmatrix}$$

a) Izračunajte svojstvene vrijednosti i svojstvene vektore zadane matrice

$\det(R - \lambda I) = 0$

$$\det(R-\lambda I) = \begin{vmatrix} 4-\lambda & 0 & -2 \\ 0 & 2-\lambda & 0 \\ -2 & 0 & -4-\lambda \end{vmatrix} \begin{matrix} 4-\lambda & 0 \\ 0 & 2-\lambda \\ -2 & 0 \end{matrix} =$$

$$= (4-\lambda)(2-\lambda)(-4-\lambda) - 4(2-\lambda) = 0$$

$$\det(R-\lambda I) = (8 - 6\lambda + \lambda^2)(-4-\lambda) - 8 + 4\lambda = (-32 - 12\lambda - 4\lambda^2 - \lambda^3) - 8 + 4\lambda = -\lambda^3 - 4\lambda^2 - 8\lambda - 40$$

~~KRIVO ZADAN ZADATAK!~~ (dobivaju se kompleksne vrijednosti)

~~ISPRAVNA MATRICA~~

NIJE, OK JE :)

$$R = \begin{bmatrix} 4 & 0 & -2 \\ 0 & 2 & 0 \\ -2 & 0 & 4 \end{bmatrix} \rightarrow \text{pozitivan (ZZV 17)}$$

$$\det(R-\lambda I)=\begin{vmatrix} 4-\lambda & 0 & -2 \\ 0 & 2-\lambda & 0 \\ -2 & 0 & 4-\lambda \end{vmatrix}\begin{matrix} 4-\lambda & 0 \\ 0 & 2-\lambda \\ -2 & 0 \end{matrix} = (4-\lambda)(2-\lambda)(4-\lambda)-4(2-\lambda)=$$

$$=(8-6\lambda+\lambda^2)(4-\lambda)-4(2-\lambda)=32-8\lambda-24\lambda+6\lambda^2+4\lambda^2-8+4\lambda-\lambda^3=$$

$$=-\lambda^3+10\lambda^2-28\lambda+24 \Rightarrow \quad \lambda_1=6\,,\ \lambda_2,\lambda_3=2$$

$\lambda_1=6)$

$$(R-\lambda I \,\vdots\, 0)=\left[\begin{array}{ccc|c} -2 & 0 & -2 & 0 \\ 0 & -4 & 0 & 0 \\ -2 & 0 & -2 & 0 \end{array}\right] \Rightarrow \left.\begin{array}{l} -x_1-x_3=0 \\ x_2=0 \end{array}\right\} \begin{array}{l} x_1=-x_3 \\ x_2=0 \end{array} \Rightarrow x=\begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}=x_1\begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}$$

$\lambda_{2,3}=2)$

$$(R-\lambda I \,\vdots\, 0)=\left[\begin{array}{ccc|c} 2 & 0 & -2 & 0 \\ 0 & 0 & 0 & 0 \\ -2 & 0 & 2 & 0 \end{array}\right] \Rightarrow \left.\begin{array}{l} x_1=x_3 \\ x_2 \end{array}\right\} x=\begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}=x_1\begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}+x_2\begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$

$$x_1^2+x_3^2=1 \Rightarrow 2x_1^2=1 \Rightarrow x_1=\frac{1}{\sqrt{2}}$$

$$v_1=\begin{bmatrix} 1/\sqrt{2} \\ 0 \\ -1/\sqrt{2} \end{bmatrix},\ v_2=\begin{bmatrix} 1/\sqrt{2} \\ 0 \\ 1/\sqrt{2} \end{bmatrix},\ v_3=\begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$ (nije bitan poredak u T matrici)

b) $T=\begin{bmatrix} v_1 & v_3 & v_2 \end{bmatrix}$ $\qquad T=\begin{bmatrix} 1/\sqrt{2} & 0 & 1/\sqrt{2} \\ 0 & 1 & 0 \\ -1/\sqrt{2} & 0 & 1/\sqrt{2} \end{bmatrix}$

$$T^H R T=\begin{bmatrix} 1/\sqrt{2} & 0 & -1/\sqrt{2} \\ 0 & 1 & 0 \\ 1/\sqrt{2} & 0 & 1/\sqrt{2} \end{bmatrix}\begin{bmatrix} 4 & 0 & -2 \\ 0 & 2 & 0 \\ -2 & 0 & 4 \end{bmatrix}\begin{bmatrix} 1/\sqrt{2} & 0 & 1/\sqrt{2} \\ 0 & 1 & 0 \\ -1/\sqrt{2} & 0 & 1/\sqrt{2} \end{bmatrix}=\begin{bmatrix} \frac{6}{\sqrt{2}} & 0 & -\frac{6}{\sqrt{2}} \\ 0 & 2 & 0 \\ \frac{2}{\sqrt{2}} & 0 & \frac{2}{\sqrt{2}} \end{bmatrix}\begin{bmatrix} \frac{1}{\sqrt{2}} & 0 & \frac{1}{\sqrt{2}} \\ 0 & 1 & 0 \\ -\frac{1}{\sqrt{2}} & 0 & \frac{1}{\sqrt{2}} \end{bmatrix}$$

$$=\begin{bmatrix} 6 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 2 \end{bmatrix}$$

c) ŠTO JE TO RESTRIKCIJA BAZE?

Restrikcija baze je redukcija broja uzoraka u bloku u frekvencijskoj domeni

- Trokutasta restrikcija

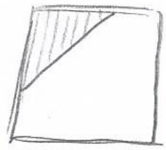

- Kvadratna restrikcija

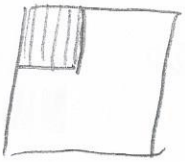

d)

$$v_1 = \begin{bmatrix} 1/\sqrt{2} \\ 0 \\ -1/\sqrt{2} \end{bmatrix} \quad v_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \quad v_3 = \begin{bmatrix} 1/\sqrt{2} \\ 0 \\ 1/\sqrt{2} \end{bmatrix}$$

1.3. $f(ax) \circ\!\!-\!\!\bullet \frac{1}{|a|} F\left(\frac{u}{a}\right)$ $\qquad F(f(t)) = \int_{-\infty}^{\infty} f(t) e^{-i\omega t} dt$

$$F(f(at)) = \int_{-\infty}^{\infty} f(at) e^{-i\omega t} dt = \left| \text{supst. } x = at \right| = \int_{-\infty}^{\infty} f(x) e^{-i\omega \frac{x}{a}} \frac{1}{a} dx =$$

$$= \frac{1}{a} \int_{-\infty}^{\infty} f(x) e^{-i\omega \frac{x}{a}} =$$ | zbog okretanja granica za negativne vrijednosti skalara a stavljamo apsolutnu vrijednost. Na taj način $F\{f(-t)\}(\omega) = F\{f(t)\}(-\omega)$ ostaje zadovoljeno* |

$$= \frac{1}{|a|} F\left(\frac{x}{a}\right)$$

*ako je $a<0$ tada $a=-|a|$

$F\{f(at)\} = F\{f(-|a|t)\}(\omega) = F\{f(|a|t\}(-\omega)$

(2.) Histogrami

(2.1.) OBJASNITE ŠTO JE TO HISTOGRAM

Histogram prvog reda neke slike predstavlja relativnu frekvenciju pojave različitih vrijednosti točaka u slici

(2.2) HISTOGRAM DRUGOG REDA

Histogram drugog reda predstavlja relativnu frekvenciju pojave parova točaka u slici (autokorelaciju za određeni pomak unutar slike)

$$P = \frac{N(x_1, x_2)}{N}$$

$N(x_1, x_2)$ → broj parova točaka x_1 i x_2

N → broj točaka unutar prozora

(2.3)

$$T = \underbrace{\begin{bmatrix} 1 & 2 & 3 & \cdots & N \\ 1 & 2 & 3 & \cdots & N \\ \vdots & \vdots & \vdots & \ddots & \\ 1 & 2 & 3 & \cdots & N \end{bmatrix}}_{N} \Bigg\} M$$

a) $\mu(1,0)$

$$\frac{1}{M(N-1)} \underbrace{\begin{bmatrix} 0 & 0 & 0 & \cdots & 0 & 0 \\ N-1 & 0 & 0 & \cdots & 0 & 0 \\ 0 & N-1 & 0 & & \vdots & \\ 0 & 0 & N-1 & & \vdots & \\ \vdots & \vdots & \vdots & & \vdots & \\ 0 & 0 & 0 & & N-1 & 0 \end{bmatrix}}_{N-1} \Bigg\} N-1$$

b)

Energija

$$S_G = \sum\sum [P(x_1, x_2)]^2 = \cancel{(N-1)} \cdot \frac{N-1}{M\cancel{(N-1)}} = \frac{N-1}{M}$$

Entropija

$$S_H = \sum\sum P(x_1, x_2) \log_2 P(x_1, x_2) = (N-1) \left[\frac{\cancel{N-1}}{M\cancel{(N-1)}} \cdot \log_2 \frac{1}{M} \right] = \frac{N-1}{M} \log_2 \frac{1}{M}$$

c) $N=1024$, $M=1024$

$$S_H = \frac{N-1}{M} \log_2 \frac{1}{M} = 9{,}95$$

d)

$\frac{N}{4}$ jer histogram prvog reda ima N točaka i jednako su sve zastupljene

3. SEGMENTACIJA SLIKE

3.1 Amplitudna segmentacija slike je izdvajanje dijelova slike prema vrijednostima njenih točaka (piksela)

3.2 Tomita segmentacija je rekurzivna segmentacija na regije prema histogramu:

1) odredi prag te prema njegovoj vrijednosti podijeli sliku u dvije regije
2) Izračunaj histogram za svaku od regija
   - 2.1) Ako je histogram bimodalan regija se dijeli u dva dijela
   - 2.2) Ako je histogram unimodalan regija se ne dijeli
3) Rekurzivno ponavljaj dok histogrami svih regija ne postanu unimodalni

3.3.

a) $x\cos\vartheta + y\sin\vartheta = \rho$

b) NE – preslikava se u točku u koordinatnom sustavu (ϑ, ρ)

c) $(3,0)$
$(1,2)$
$(0,3)$

familija pravaca kroz točku se preslikava u sinusoide

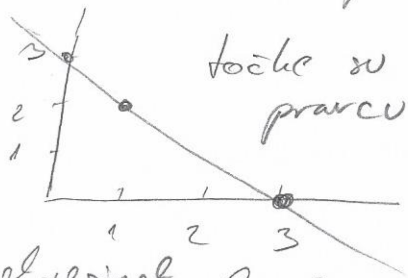

točke su na istom pravcu!

$\rho_1 = 3\cos\vartheta + 0 \cdot \sin\vartheta$ $\quad \rho_2 = \cos\vartheta + 2\sin\vartheta$ $\quad \rho_3 = 3\sin\vartheta$

$\vartheta_1 = 0° \rightarrow \rho_{11} = 3$ $\quad \rightarrow \rho_{21} = 1$ $\quad \rightarrow \rho_{31} = 0$

$\vartheta_2 = 45° \rightarrow \rho_{12} = \frac{3\sqrt{2}}{2}$ $\quad \rightarrow \rho_{22} = \frac{3\sqrt{2}}{2}$ $\quad \rightarrow \rho_{32} = \frac{3\sqrt{2}}{2}$

$\vartheta_3 = 90° \rightarrow \rho_{13} = 0$ $\quad \rightarrow \rho_{23} = 2$ $\quad \rightarrow \rho_{33} = 3$

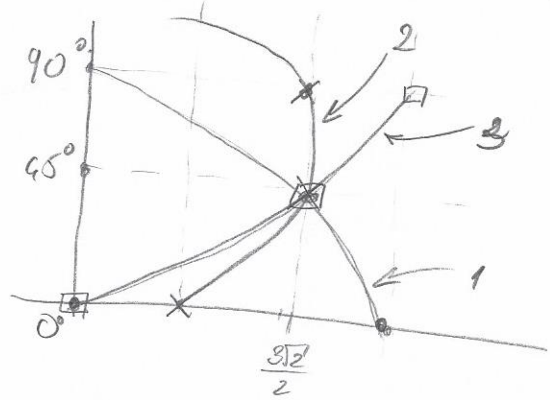

d) $A(\vartheta, \rho) = M$

Rezultat Houghove transformacije je polje brojeva $A(p,q)$
Vrijednost $A(p,q) = M$ znači da postoji M točaka koje leže na pravcu određenom parametrima ρ_p, ϑ_q

3.4. Koristi se prikaz slike pomoću kvartarnog stabla, gdje se svaka grana dijeli u četiri grane, a inicijalna regija je cijela slika

1) Ako je regija neuniformna, razbij ju u četiri podregije

2) Ako su četiri susjedne regije uniformne, spoji ih u jednu regiju

$\rightarrow$ uniformnost se mjeri npr. pomoću razlike svjetline najtamnije i najsvjetlije točke u regiji

3.5.

// Inicijaliziraj k na broj koliko grupa želiš
k = broj
// k puta nasumično odredi centar grupe, μ u nultoj iteraciji
$\mu(0)$ = rand
while $(\mu(n) \neq \mu(n+1))$ {

// odaberi vektor x_i i dodijeli ga grupi čijem je centru najbliži

$$x_i \in R_i \Leftrightarrow d(x_i, \mu_k(n)) = \min_{j=1,\dots,k} \{ d(x_i, \mu_j(n)) \}$$

// Izračunaj nove centre grupa

$$\mu(n+1) = \sum_{x_i \in R_k} d(x_i, \mu_k(n+1)) = \min_y \{ d(x_i, y) \}, \quad k = 1, \dots, k$$

3.6.

$$R = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 8 & 9 \\ 2 & 2 & 3 \end{bmatrix} \quad G = \begin{bmatrix} 4 & 5 & 6 \\ 2 & 2 & 2 \\ 1 & 8 & 1 \end{bmatrix} \quad B = \begin{bmatrix} 8 & 8 & 8 \\ 2 & 1 & 1 \\ 3 & 1 & 1 \end{bmatrix}$$

$$d(A,B) = \sum_{i=1}^{N} |A_i - B_i|$$

a)

3.7 Tehnike izrastanja područja:

1) na osnovi sličnosti dvaju susjednih točaka
→ točke su slične ako je njihova razlika manja od 5

2) na osnovi sličnosti okolina dvaju susjednih točaka

3) na osnovi sličnosti točke i centroida regije

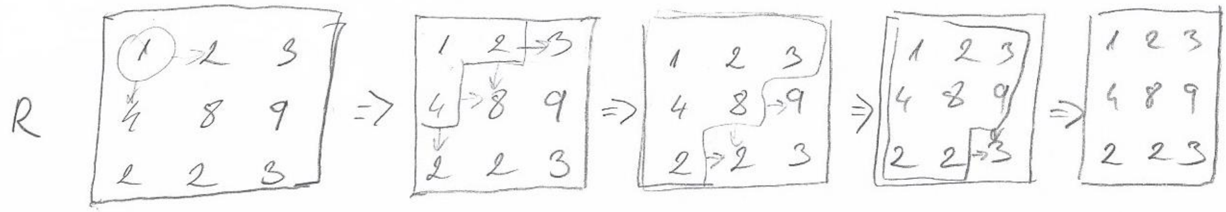

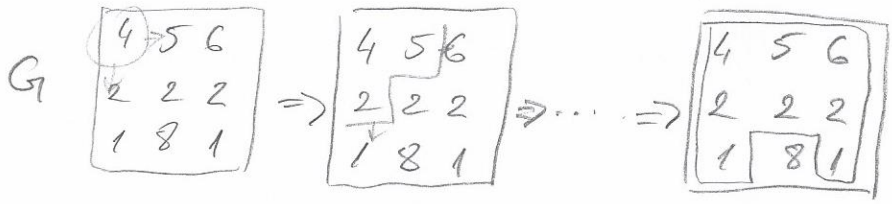

3.8. Ideja ekspertnih sustava je da se umjetnim sustavom imitira znanje ljudskog eksperta odnosno omogući rješavanje različitih problema. Oni su obično usko specijalizirani, a koriste se u obradi, analizi i razumijevanju slika

3.9. 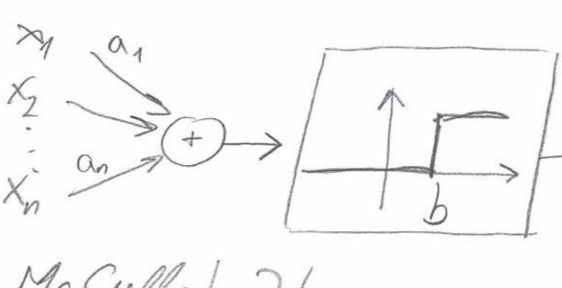

$y = S\left(\sum_i a_i x_i - b\right)$

McCulloch-Pits

multi-layer feed-forward network

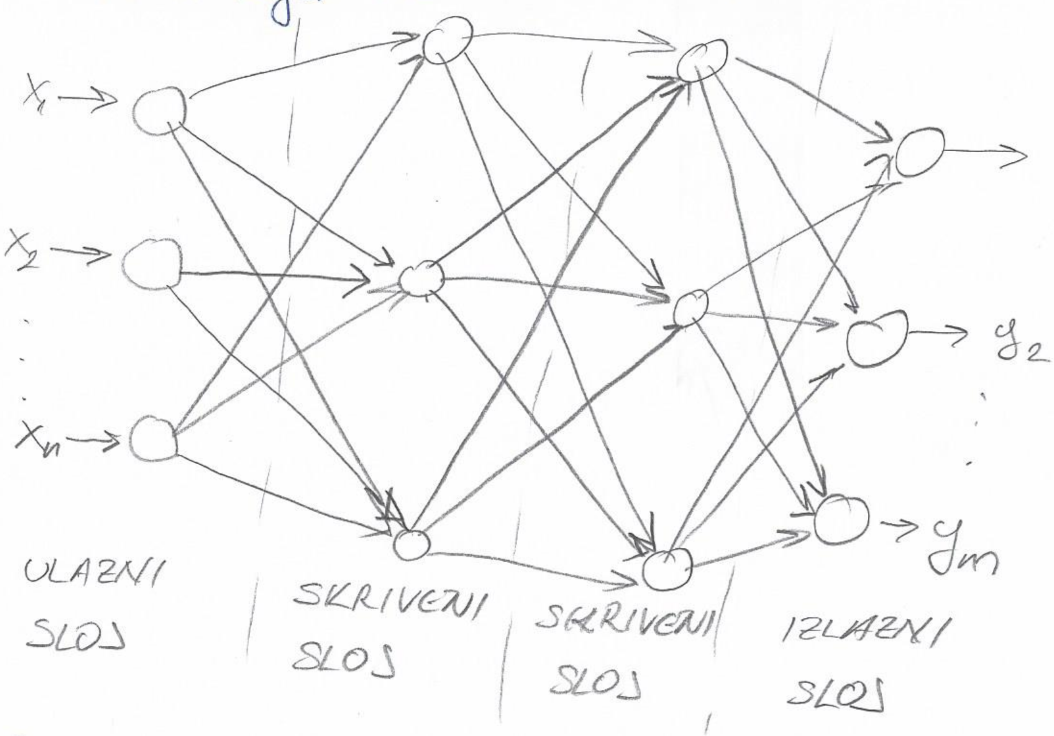

4 EKSTRAKCIJA ZNAČAJKI

4.1 Detekcija se obavlja konvolucijom impulsnog odziva $h(x)$ i zašumljenog signala $f(x)$, a rub se označava na mjestu maksimalnog odziva u konvoluciji signala $h(x)$ i $f(x)$

Svojstva Canny maske:

1) Dobra detekcija (maksimizacija SNR kod odziva)
2) Dobra lokalizacija (izbjegavanje pogrešnog označavanja mjesta ruba)
3) Jedan odziv (dovoljno je da postoji samo jedan detektirani rub)

4.2

$$\begin{bmatrix} 1 & 1 & 1 \\ 0 & 0 & 0 \\ -1 & -1 & -1 \end{bmatrix} \uparrow, \quad \begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix} \rightarrow, \quad \begin{bmatrix} -1 & -1 & -1 \\ 0 & 0 & 0 \\ 1 & 1 & 1 \end{bmatrix} \downarrow, \quad \begin{bmatrix} 1 & 0 & -1 \\ 1 & 0 & -1 \\ 1 & 0 & -1 \end{bmatrix} \leftarrow$$

4.3

$$S = \begin{bmatrix} 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 1 & 1 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

a)

$$S_H = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix} \downarrow \quad S_H' = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix}$$

(flip gore-dolje + flip lijevo-desno)

$$g = \begin{bmatrix} -3 & -4 & -4 & -3 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

(samo dijelovi za koje je cijela maska unutar slike, „valid“)

b)

$$S_V = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix} \quad S_V' = \begin{bmatrix} 1 & 0 & -1 \\ 2 & 0 & -2 \\ 1 & 0 & -1 \end{bmatrix}$$

$$g = \begin{bmatrix} -1 & 0 & 0 & 1 \\ -2 & 0 & 0 & 2 \end{bmatrix}$$

d) Standardna devijacija u okolini $W \times W$

$$\sigma(j,k) = \frac{1}{W^2} \sum_{m=-w}^{w} \sum_{n=-w}^{w} \left[x(j+m, k+n) - M(j+m, k+n) \right]^2$$

srednja vrijednost $\rightarrow$ $$M(j,k) = \frac{1}{W^2} \sum_{m=-w}^{w} \sum_{n=-w}^{w} x(j+m, k+n)$$

$$\boxed{W = 2w+1} \; !$$

$$M(j,k) = \frac{1}{3^2} \cdot \sum_{-2}^{2} \sum_{-2}^{2} \left[S(j+m, k+n) \right] = \frac{1}{3^2} \begin{bmatrix} 0 & 0 & 0 & 0 & 0 & 0 \\ 1 & 2 & 3 & 3 & 2 & 1 \\ 1 & 2 & 3 & 3 & 2 & 1 \\ 1 & 2 & 3 & 3 & 2 & 1 \end{bmatrix} =$$

$$\sigma = \frac{1}{3^2} \begin{bmatrix} 0 & 0 & 0 & 0 & 0 & 0 \\ -\frac{1}{9} & -\frac{2}{9} & -\frac{3}{9} & -\frac{3}{9} & -\frac{2}{9} & -\frac{1}{9} \\ -\frac{1}{9} & \frac{7}{9} & \frac{6}{9} & \frac{6}{9} & \frac{7}{9} & -\frac{1}{9} \\ -\frac{1}{9} & -\frac{2}{9} & -\frac{3}{9} & -\frac{3}{9} & -\frac{2}{9} & -\frac{1}{9} \end{bmatrix} = \frac{1}{3^4} \begin{bmatrix} 0 & 0 & 0 & 0 & 0 & 0 \\ -1 & -2 & -3 & -3 & -2 & -1 \\ -1 & 7 & 6 & 6 & 7 & -1 \\ -1 & -2 & -3 & -3 & -2 & -1 \end{bmatrix}$$

4.4.

$$\nabla^2 f = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2} \qquad G = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}}$$

$$\frac{\partial f}{\partial x} = \frac{1}{\cancel{2\pi\sigma^2}} \cdot \frac{-1}{\cancel{2\sigma^2}} \cdot \cancel{2}x \cdot e^{-\frac{x^2+y^2}{2\sigma^2}} = \frac{-x}{2\pi\sigma^4} e^{-\frac{x^2+y^2}{2\sigma^2}}$$

$$\frac{\partial^2 f}{\partial x^2} \Rightarrow -\frac{1}{2\pi\sigma^4} e^{-\frac{x^2+y^2}{2\sigma^2}} + \frac{\cancel{2}x^2}{2\pi\sigma^4} \cdot \frac{1}{\cancel{2}\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}}$$

$$\frac{\partial^2 f}{\partial y^2} \Rightarrow -\frac{1}{2\pi\sigma^4} e^{-\frac{x^2+y^2}{2\sigma^2}} + \frac{y^2}{2\pi\sigma^4} \cdot \frac{1}{\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}}$$

$$LoG = \left[-\frac{\cancel{2}}{\cancel{2}\pi\sigma^4} + \frac{x^2+y^2}{2\pi\sigma^8} \right] e^{-\frac{x^2+y^2}{2\sigma^2}} = -\frac{1}{\pi\sigma^4} \left[1 - \frac{x^2+y^2}{2\sigma^2} \right] e^{-\frac{x^2+y^2}{2\sigma^2}}$$

5 ANALIZA OBLIKA

5.1
1) Granične skalarne transformacije
2) Granične metode u domeni prostora
3) Globalne skalarne transformacije
4) Globalne metode u domeni prostora

5.2 Granične skalarne transformacije su izvođenje 1D funkcija iz 2D granice objekta. Dobivena funkcija opisuje se potom nekom metodom. Na taj način se 2-D oblik indirektno predstavlja opisom 1D fje

5.3. Kod stohastičkih metoda se izvedena 1D funkcija modelira pomoću diskretnih stohastičkih procesa, a parametri stohastičkog modela dobiveni modeliranjem koriste se za opis oblika.

5.4 Jedna od dvije metode za analizu kompletnog oblika (Globalne metode u domeni prostora):

1) Transformacija simetrične osi

2) Tehnike dekompozicije slike

Transformacija simetrične osi:

- Metoda opisuje oblik pomoću grafa koji bi trebao sačuvati topološke značajke oblika.

Kreće se jednakom brzinom od robova prema središto (okomito na robove) i traži se kostur oblika. Kostur oblika čine sve „točke sudara"

5.5

		P	R	V	E	N	S	T	V	O
	0	1	2	3	4	5	6	7	8	9
G	1	1	2	3	4	5	6	7	8	9
O	2	2	2	3	4	5	6	7	8	8
L	3	3	3	3	4	5	6	7	8	8

5.6

			P	R	V	E	N	S	T	V	O
		0	1	2	3	4	5	6	7	8	9
	G	1	1	2	3	4	5	6	7	8	9
	O	2	2	2	3	4	5	6	7	8	9
	O	3	3	3	3	4	5	6	7	8	8
	⋮	⋮									
	O	8	8	8	8	8	8	8	8	8	8
	O	9	9	9	9	9	9	9	9	9	8
	O	10	10	10	10	10	10	10	10	10	9
	⋮										
(N)	O	N+1	N+1	N+1	N+1	N+1	N+1	N+1	N+1	N+1	N
	L	N+2	N+2	N+2	N+2	N+2	N+2	N+2	N+2	N+2	N+1

6. ANALIZA POKRETA

6.1 Kros korelacija u analizi pokreta je računanje korelacije malih regija (npr. 8x8) u dvjema slikama iz niza

Mana - nije moguće formulirati kriterij koji zahtjeva glatkoću polja kretanja (vektori pokreta se računaju potpuno nezavisno za svaku lokaciju)

Prednost - jednostavnost metode

6.2 Neka je $I(x,y,t)$ svjetlina slike u točki s koordinatama (x,y) i u trenutku t

Ako je (x,y) dio objekta koji se pomakne onda vrijedi

$$I(x+dx, y+dy, t+dt) = I(x,y,t)$$

(izraz pretpostavlja da je osvjetljenje jednako)

$$I_x dx + I_y dy + I_t dt = 0$$

$$\left[I_x = \frac{dI}{dx}, \; I_y = \frac{dI}{dy}, \; I_t = \frac{dI}{dt} \right]$$

$$I_t dt = -(I_x dx + I_y dy) \quad / : dt$$

$$I_t = -\left(I_x \frac{dx}{dt} + I_y \frac{dy}{dt}\right)$$

brzine u x i y smjeru

$$I_t = -(I_x v_x + I_y v_y)$$

$$v = \begin{bmatrix} v_x \\ v_y \end{bmatrix} \Rightarrow I_t = -\nabla I \cdot v$$

6.3.

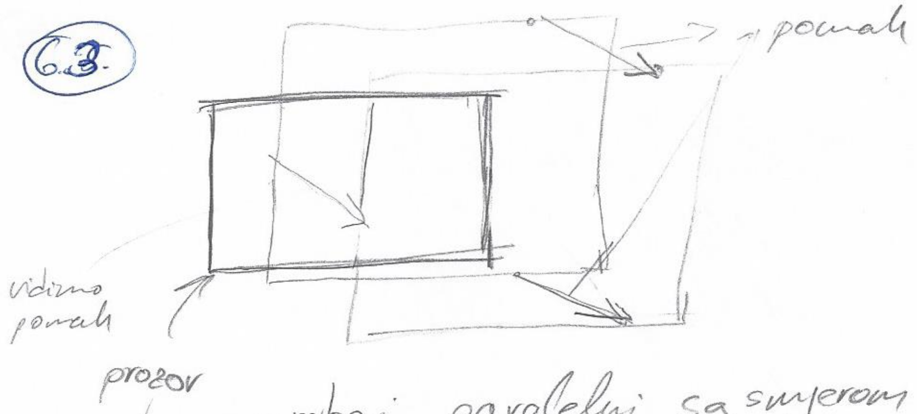

- rubovi paralelni sa smjerom gibanja izgledaju kao da se ne miču

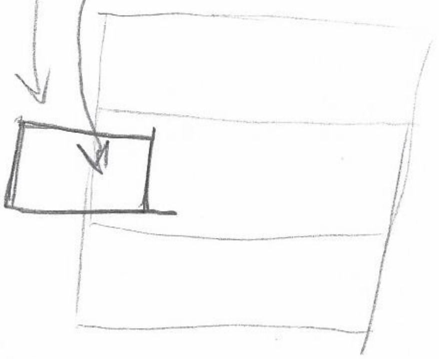

6.5.

H-S algoritam problem računanja optičkog toka svodi na problem minimizacije izraza koji se sastoji od dva člana

$E_1 = I_x v_x + I_y v_y + I_t$ – odstupanje od jednadžbe za optički tok (u idealnom slučaju je $\emptyset$)

$E_2 = \left(\frac{\delta v_x}{\delta x}\right)^2 + \left(\frac{\delta v_y}{\delta y}\right)^2 + \left(\frac{\delta v_y}{\delta x}\right)^2 + \left(\frac{\delta v_x}{\delta y}\right)^2$ – član koji zahtijeva glatkoću vektorskog polja

- pretvara loše postavljeni problem u dobro postavljeni problem

(6.6.)

1) Translacija (konstantna udaljenost od promatrača)

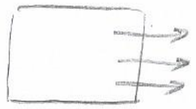

2) Translacija (približavanje, širenje)

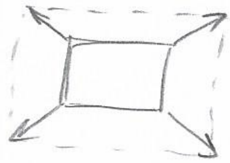

3) Rotacija (oko osi koja je okomita na sliku)

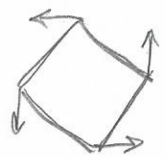

4) Rotacija (oko osi koja je u ravnini slike

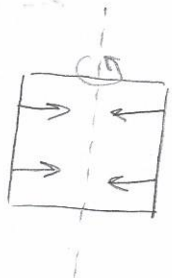

(6.7)